

Reconstrução de Waveform na Avaliação de Audio XAI

Literatura, mecanismo e evidência experimental

Larissa de Andrade Silva

PPGI / IComp / UFAM

24 de setembro de 2026

Questão: quando uma perturbação espectral-temporal precisa voltar ao domínio da waveform, a reconstrução pode alterar a própria mensuração de faithfulness?

A ideia em uma frase

A literatura já mostra três coisas separadamente:

Audio XAI

Explicações espectrais podem ser convertidas novamente em áudio [1], [2], [3].

Perturbação

A escolha da intervenção pode alterar explicações e avaliações [4], [5].

Reconstrução

Magnitude modificada e fase formam um problema de reconstrução não trivial [6].

Nossa pergunta conecta essas três linhas: se a perturbação for mantida fixa, mudar apenas o operador de reconstrução pode mudar a avaliação XAI?

Por que a reconstrução não é uma etapa puramente mecânica?

Uma magnitude perturbada $\tilde{A}_{b,d}$ não determina uma única waveform. Para obter um sinal temporal, é preciso especificar também como a fase será tratada.

Original Phase (OP)

$$\tilde{x}_{\text{OP}} = \text{iSTFT}\left(\tilde{A}_{b,d}e^{j\Phi}\right).$$

- ▶ reutiliza a fase original Φ ;
- ▶ é simples e aparece em métodos listenable [2], [3];
- ▶ após modificar a magnitude, o espectrograma complexo imposto pode deixar de ser consistente com uma STFT realizável.


Griffin–Lim, 64 iterações (GL64)

$$\tilde{x}_{\text{GL64}} = R_{\text{GL64}}(\tilde{A}_{b,d}; \Phi).$$

- ▶ parte da mesma magnitude e da mesma fase inicial;
- ▶ alterna projeções entre representação TF e waveform;
- ▶ procura reduzir a discrepância entre a STFT obtida e a magnitude-alvo [6].

A máscara pode ser idêntica, mas a waveform entregue ao classificador não precisa ser.

Onde o reconstrutor entra na medida



A métrica não observa diretamente a máscara. Ela observa scores produzidos a partir das waveforms reconstruídas:

$$F(E; R) = \mathcal{M}\left(\{f(R(\tilde{A}_E(q)))\}_q\right).$$

Logo, com a atribuição e a perturbação fixas,

$$F(E; R_1) \neq F(E; R_2)$$

é uma possibilidade experimentalmente testável, não uma propriedade assumida.

O que a literatura já cobre

Linha		Evidência existente	Limite para nossa pergunta
Ressíntese XAI	em	Griffin–Lim ou fase original já foram usados para tornar explicações audíveis [1], [2], [3], [7]	o reconstrutor costuma permanecer fixo
Perturbation XAI		replacement / masking pode afetar a explicação ou a avaliação [4], [5]	estuda o operador de intervenção, não a etapa posterior de síntese
Time-domain explanations	ex-	LMAC-TD evita a inversão de magnitude e discute artefatos de reconstrução [8]	domínio, arquitetura e síntese mudam conjuntamente
Reconstrução de STFT	de	phase retrieval e consistência da STFT são problemas clássicos [6]	não examinam validade de benchmark XAI

Os trabalhos mais próximos

Parekh et al. e L-MAC [2], [3]

- ▶ aplicam máscaras no espectrograma;
- ▶ reconstroem usando a fase original;
- ▶ mostram que a reconstrução faz parte do pipeline listenable.

Halpern et al. e Lim et al. [1], [7]

- ▶ usam Griffin–Lim como técnica de ressíntese;
- ▶ não o variam como fator de avaliação.

SoundLIME / SLIME e AIM [4], [5]

- ▶ demonstram que decisões de masking / replacement importam;
- ▶ AIM chega a examinar estabilidade de rankings sob operadores de masking.

LMAC-TD [8]

- ▶ é o que chega mais próximo;
- ▶ evita a inversão magnitude-STFT;
- ▶ mas não mantém a mesma perturbação enquanto varia somente R .

Como definimos o gap

Não basta encontrar um paper que mencione phase retrieval ou áudio reconstruído. Para responder diretamente à nossa pergunta, o estudo precisaria satisfazer simultaneamente:

1. avaliação perturbacional de Audio XAI;
2. mesma atribuição e mesma perturbação TF;
3. pelo menos dois operadores de reconstrução waveform;
4. efeito de R quantificado em faithfulness, ranking ou conclusão comparativa.

Na busca realizada, recuperamos 58 candidatos e não encontramos um estudo que satisfizesse os critérios simultaneamente.

Isso sustenta um claim de novidade do tipo “to our knowledge”, não uma prova lógica de inexistência.

Onde está o espaço ainda aberto?

Trabalho	waveform reconstruída?	operador explícito?	operador variado?	faithfulness?	consequência comparativa?
Halpern et al. 2020 [1]	sim	GL	não	limitado	não
Mishra et al. 2020 [4]	não necessário	–	masking	sim	masking
Parekh et al. 2022 [2]	sim	fase original	não	sim	não
L-MAC 2024 [3]	sim	fase original	não	sim	não
LMAC-TD 2025 [8]	sim	muda domínio	não isolado	sim	não isolado
AIM 2026 [5]	depende	masking	masking	sim	sim, masking
Nossa pergunta	sim	OP / GL64	sim	sim	sim

Isolar a reconstrução waveform como variável da mensuração, não descobrir que áudio pode ser reconstruído de maneiras diferentes.

Formulação


Embora estudos de Audio XAI usem ressíntese de waveform e estudos de faithfulness já mostrem sensibilidade a escolhas de masking, **não encontramos, na literatura examinada, uma avaliação que mantenha fixa a intervenção espectraltemporal e isole o operador de reconstrução como fator experimental**, quantificando seu efeito sobre faithfulness e conclusões comparativas entre explicadores.

A pergunta operacional é simples:

Mesma explicação + mesma perturbação + outro $R \Rightarrow$ mesma conclusão XAI?

Geralmente essa variável não foi isolada no protocolo de mensuração.

Experimento mínimo que identifica o efeito de reconstrução



Fixos: modelo, input, explicador, ranking, máscara, percentil, ganho ($\alpha = 0.01$, -40 dB), STFT e protocolo de avaliação.

OP vs. GL64 é o instrumento experimental; a contribuição é testar a validade da mensuração quando R muda.

Referência pareada: uma proteção importante do protocolo

A reconstrução pode deslocar o próprio áudio mesmo antes da remoção / retenção de regiões. Por isso, cada ramo deve ter sua própria referência reconstruída:

$$x_{R,\text{full}} = R(A), \quad x_{R,b,d} = R(\tilde{A}_{b,d}).$$

O efeito da perturbação é então calculado dentro do mesmo operador:

$$D_R(b, d) = f(x_{R,b,d}) - f(x_{R,\text{full}}).$$

A referência pareada não elimina toda diferença entre reconstrutores. Ela evita confundir o deslocamento basal de R com o efeito da perturbação que queremos medir.

Evidência 1: a diferença aparece primeiro no sinal

Com ranking, máscara e magnitude-alvo fixos, OP e GL64 diferem em diagnósticos físicos de reconstrução nos dois datasets.

Diagnósticos

- ▶ discrepância / convergência espectral;
- ▶ energia residual na região atenuada;
- ▶ erro na região atenuada;
- ▶ desvio RMS absoluto.

Leitura correta

- ▶ GL64 pode reproduzir melhor a magnitude-alvo em certos diagnósticos;
- ▶ isso confirma que os dois ramos realizam a mesma intervenção TF de forma diferente;
- ▶ **isso não estabelece que GL64 produza uma explicação mais fiel.**

O diagnóstico de sinal sustenta o mecanismo. A contribuição XAI exige mostrar que a diferença se propaga até o score ou a conclusão do benchmark.

Evidência 2: a geometria downstream pode modular a propagação

DB3V: agregação afim

$$\bar{\mathbf{z}}_j = \frac{1}{n_j} \sum_k \mathbf{z}_{jk}$$

Uma alteração local entra na média como

$$\delta \bar{\mathbf{z}}_j = \frac{1}{n_j} \delta \mathbf{z}_{jk}.$$

No experimento atual, nenhum contraste primário de ΔAUC permaneceu significativo após Holm.

Interpretação: o mean-pooling é compatível com amortecimento do efeito local.

Curruíra: média de probabilidades + logit

$$\bar{p}_i = \frac{1}{m_i} \sum_r p_{ir}, \quad g(\bar{p}_i) = \log \frac{\bar{p}_i}{1 - \bar{p}_i}$$

$$\frac{\partial g}{\partial p_{ir}} = \frac{1}{m_i \bar{p}_i (1 - \bar{p}_i)}.$$

As divergências locais mostraram $\rho = 0.835$ (GEFA) e $\rho = 0.753$ (KernelSHAP), acompanhadas de contraste direcional em IN.

Interpretação: a transformação não linear pode tornar certas regiões de probabilidade mais sensíveis.

Evidência 3: a escolha de R pode chegar ao benchmark comparativo

No Curruíra, avaliamos a vantagem do explicador sobre o baseline de densidade de energia sob os dois operadores.

Explicador	Resultado sob os operadores	Contraste direto de reconstrução
GEFA (IN)	vantagem suportada sob OP, mas não sob GL64 após correção	$\Delta\text{Adv} = 0.0565$, IC 95% $[0.0168, 0.1074]$, $p_{\text{Holm}} = 0.0154$
KernelSHAP (IN)	vantagem permanece sob ambos, mas muda de magnitude	$\Delta\text{Adv} = 0.0317$, $p_{\text{Holm}} = 0.0056$

O resultado não estabelece uma hierarquia $\text{OP} > \text{GL64}$ ou $\text{GL64} > \text{OP}$. Ele mostra dependência da conclusão quantitativa em relação ao operador.

Cuidado estatístico e causal

Há duas distinções que precisam permanecer explícitas:

Significância

Não basta dizer:

$$p_{\text{OP}} < 0.05, \quad p_{\text{GL64}} > 0.05.$$

A evidência de diferença entre operadores vem do contraste direto:

$$\Delta\text{Adv} = \text{Adv}_{\text{OP}} - \text{Adv}_{\text{GL64}}.$$


Causalidade

O experimento identifica o efeito de R apenas se todo o restante do pipeline for realmente mantido fixo.

Por isso, é mais seguro falar em **efeito controlado do operador de reconstrução** do que em uma teoria causal geral sobre todos os pipelines Audio XAI.

Um confundidor que precisamos controlar: $\text{mel} \rightarrow \text{STFT}$

Se a perturbação é definida em log-mel, existe uma etapa adicional antes da reconstrução de fase.




Se a inversão $\text{mel} \rightarrow \text{linear}$ e a reconstrução de fase mudarem juntas, o efeito não pode ser atribuído exclusivamente a R . O controle ideal separa essas etapas ou usa magnitude STFT linear.

Possível contribuição

- ▶ formalizar R dentro do estimando de faithfulness;
- ▶ isolar R com intervenção TF fixa;
- ▶ usar referência pareada por operador;
- ▶ mostrar propagação sinal $\rightarrow$ modelo $\rightarrow$ benchmark;
- ▶ discutir como a agregação downstream modula essa propagação.

Síntese



Quando a avaliação perturbacional precisa reconstruir waveform, o operador de reconstrução deve ser tratado como parte explícita da especificação experimental da medida de faithfulness.

Referências centrais I

- [1] B. M. Halpern, F. Kelly, R. J. J. H. van Son, and A. Alexander, “Residual networks for resisting noise: Analysis of an embeddings-based spoofing countermeasure,” in *The Speaker and Language Recognition Workshop (Odyssey 2020)*, 2020, pp. 326–332. DOI: [10.21437/Odyssey.2020-46](https://doi.org/10.21437/Odyssey.2020-46)
- [2] J. Parekh, S. Parekh, P. Mozharovskyi, F. d’Alché-Buc, and G. Richard, “Listen to interpret: Post-hoc interpretability for audio networks with NMF,” in *Advances in Neural Information Processing Systems*, 2022. DOI: [10.52202/068431-2556](https://doi.org/10.52202/068431-2556)
- [3] F. Paissan, M. Ravanelli, and C. Subakan, *Listenable maps for audio classifiers*, Proceedings of the 41st International Conference on Machine Learning; arXiv:2403.13086, 2024. DOI: [10.48550/arXiv.2403.13086](https://doi.org/10.48550/arXiv.2403.13086)
- [4] S. Mishra, E. Benetos, B. L. Sturm, and S. Dixon, “Reliable local explanations for machine listening,” in *2020 International Joint Conference on Neural Networks (IJCNN)*, 2020, pp. 1–8. DOI: [10.1109/IJCNN48605.2020.9207444](https://doi.org/10.1109/IJCNN48605.2020.9207444)

Referências centrais II

- [5] C.-Y. Hsieh, H.-Y. Fang, and C.-S. Wei, *AIM: Adversarial information masking for faithfulness evaluation of saliency maps*, arXiv preprint arXiv:2605.16905, 2026. DOI: 10.48550/arXiv.2605.16905
- [6] D. W. Griffin and J. S. Lim, “Signal estimation from modified short-time fourier transform,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 32, no. 2, pp. 236–243, 1984. DOI: 10.1109/TASSP.1984.1164317
- [7] S.-Y. Lim, D.-K. Chae, and S. Lee, “Detecting deepfake voice using explainable deep learning techniques,” *Applied Sciences*, vol. 12, no. 8, p. 3926, 2022. DOI: 10.3390/app12083926
- [8] E. Mancini, F. Paissan, M. Ravanelli, and C. Subakan, “LMAC-TD: Producing time domain explanations for audio classifiers,” in *2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2025, pp. 1–5. DOI: 10.1109/ICASSP49660.2025.10890448

Pergunta para a discussão

Se a mesma atribuição e a mesma máscara recebem avaliações diferentes apenas porque a waveform foi reconstruída por outro operador, quanto da métrica pertence ao explicador — e quanto pertence ao protocolo de medição?